


arXiv Info System: RAG на корпусе arxiv.org




Актуальность I

Рост количества публикаций на arXiv (1991–2026)



Актуальность II



Нет ответа

ChatGPT

Which specific Indonesian term meaning playful teasing was inaccurately defined during the evaluation of context retrieval for sarcasm detection, and how is the term actually used in real contexts?

Use arXiv, answer concisely.

In the arXiv paper *Context-Aware Pragmatic Metacognitive Prompting for Sarcasm Detection* (arXiv:2511.21066), the authors noted that some Indonesian slang words in the *Twitter Indonesia Sarcastic* dataset were mis-handled by baseline models because the models lacked the necessary cultural or lexical grounding for them — particularly playful teasing terms that don't directly map to straightforward sentiment or sarcasm markers in English or standard Indonesian.

They don't single out one specific term in the abstract or main

Есть ответ, и он правильный!

arXiv Info System



What specific Indonesian term yielded an inaccurate definition during the evaluation of context retrieval for sarcasm detection, and what is its actual usage?

Answer concisely.



An inaccurate definition for the Indonesian term "cie" was retrieved by the Google search API. This term is actually a playful tease directed at a couple, meant to make them blush, not a literal lexical definition.

>


Sources (3)

3.60s

3 chunks

Какие данные используем?

- Только NLP - статьи
- Парсим данные в HTML формате
- Используем свежие публикации (2025)



Категория cs.CL (Computation and Language)



```
<html>
  <h1>Статья 1</h1>
  <figure>Изображение диаграммы</figure>
  <table>Таблица</table>
  <math>Куча MathML тегов</math>
  <section><h2>Выводы</h2><p>Текст<p></section>
</html>
```



- Удаляем мусорные теги
- Удаляем, благодарности, референсы и т.д.
- Диаграммы и картинки – только описание
- Математику сохраняем в LaTeX формате

Статья 1

[Диаграмма про X]

Бенчмарк	Значение
:-----	:-----
Bench1	0.87
Bench2	0.37

$$\frac{\frac{3}{6}}{2} = \frac{1}{4}$$

Выводы

Текст с выводами исследования

- В статьях очень важно сохранить смысл чанков
- Необходимо не прервать чанк на самом интересном
- И не перестараться с большими чанками
- Проблема: статей много, а ресурсов – мало

Название статьи

Абстракт

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere.

Введение

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. [Диаграмма про X] Fusce
posuere, magna sed pulvinar ultricies, purus lectus malesuada
libero, sit amet commodo magna eros quis urna.

Исследование

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere,

Бенчмарк	Значение
:-----	:-----
Bench1	0.87
Bench2	0.37

magna sed pulvinar ultricies, purus lectus malesuada libero, sit
amet commodo magna eros quis urna.

Выводы

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
 $\frac{\frac{3}{6}}{2} = \frac{1}{4}$. Fusce posuere, magna sed
pulvinar ultricies, purus lectus malesuada libero, sit amet
commodo magna eros quis urna.

Используем двойное чанкование

1. Сначала режем по структуре

Название статьи

Абстракт

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere.

Введение

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. [Диаграмма про X] Fusce
posuere, magna sed pulvinar ultricies, purus lectus malesuada
libero, sit amet commodo magna eros quis urna.

Исследование

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere,

Бенчмарк	Значение
:-----	:-----
Bench1	0.87
Bench2	0.37

magna sed pulvinar ultricies, purus lectus malesuada libero, sit
amet commodo magna eros quis urna.

Выводы

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
 $\frac{\frac{3}{6}}{2} = \frac{1}{4}$. Fusce posuere, magna sed
pulvinar ultricies, purus lectus malesuada libero, sit amet
commodo magna eros quis urna.

Используем двойное чанкование

1. Сначала режем по структуре
2. Потом рекурсивно

Название статьи

Абстракт

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere.

Введение

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. [Диаграмма про X] Fusce
posuere, magna sed pulvinar ultricies, purus lectus malesuada
libero, sit amet commodo magna eros quis urna.

Исследование

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere,

Бенчмарк	Значение
:-----	:-----
Bench1	0.87
Bench2	0.37

magna sed pulvinar ultricies, purus lectus malesuada libero, sit
amet commodo magna eros quis urna.

Выводы

Lorem ipsum dolor sit amet, consectetur adipiscing elit.
 $\frac{\frac{3}{6}}{2} = \frac{1}{4}$ fusce posuere, magna sed
pulvinar ultricies, purus lectus malesuada libero, sit amet
commodo magna eros quis urna.

Используем двойное чанкование

- 1. Сначала режем по структуре
- 2. Потом рекурсивно

Пример готового чанка:

Sycophancy under Pressure: Evaluating and Mitigating Sycophantic Bias via Adversarial Dialogues in Scientific QA > Mitigating Sycophancy via Pressure-Tune > Sycophancy-Oriented Dialogue Simulation:
Qwen3-1.7B-SycoPT	76.02	45.47	51.20	20	891	2.24	62	281	22.06	93.01
Qwen3-4B	85.15	68.68	74.15	450	998	45.09	156	174	89.65	48.30
Qwen3-4B-SycoPT	85.23	73.37	78.33	10	999	1.00	40	173	23.12	95.74
Qwen3-8B	90.87	63.05	65.11	695	1065	65.25	104	107	97.19	31.83
Qwen3-8B-SycoPT	90.78	69.70	72.53	206	1064	19.36	49	108	45.37	78.25
Table 4: Pressure-Tune performance on the ARC-Challenge Test Set across different model scales. The table report s metrics before and after sycophancy-targeted fine-tuning.
![Refer to caption](assets/radar.png)
Figure 5: The radar chart presents the impact of sycophancy-targeted Pressure-Tune on model performance in the GPQA-Diamond dataset.

Название статьи
Абстракт
Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere.
Введение
Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. [Диаграмма про X] Fusce posuere, magna sed pulvinar ultricies, purus lectus malesuada libero, sit amet commodo magna eros quis urna.
Исследование
Lorem ipsum dolor sit amet, consectetur adipiscing elit.
Maecenas porttitor congue massa. Fusce posuere,

Бенчмарк	Значение
:-----	:-----
Bench1	0.87
Bench2	0.37

magna sed pulvinar ultricies, purus lectus malesuada libero, sit amet commodo magna eros quis urna.
Выводы
Lorem ipsum dolor sit amet, consectetur adipiscing elit.
 $\frac{\frac{3}{6}}{2} = \frac{1}{4}$ fusce posuere, magna sed pulvinar ultricies, purus lectus malesuada libero, sit amet commodo magna eros quis urna.

- Используем open source модель в качестве эмбеддера
- Тяжелее модель – больше смысла заложено в векторы
- Но иногда задачи решаются не силой, а архитектурой

Всего чанков в датасете:


767,801




Как храним данные? DataOps

- Управляем данными через DVC (Data Version Control)
- Cold Storage – S3 хранилище
- Hot Storage – Qdrant








 Settings

Sources (Top-K)

3

Deploy 

arXiv Info System



What specific Indonesian term yielded an inaccurate definition during the evaluation of context retrieval for sarcasm detection, and what is its actual usage?




An inaccurate definition for the Indonesian term "cie" was found during the evaluation of context retrieval for sarcasm detection. The actual usage of "cie" in Indonesian is a playful tease directed at a couple, intended to make them blush rather than a literal lexical definition.

>  Sources (3)

 3.98s |  3 chunks

Ask about scientific papers...





- Context Recall (CR): 0.92
 - Context Precision (CP): 0.76
 - Answer Relevancy (AR): 0.74
 - Faithfulness (F): 0.90
-
- CR: Полнота релевантных чанков
 - CP: Точность нахождения рел. чанков
 - AR: Релевантность ответа LLM-генератора
 - F: Достоверность и галлюцинации

Валидация RAG'а – дорогой этап!

Константы:

- Размер эталонного датасета – 50 вопросов (погрешность $\pm 14\%$)
- Top_k = 10
- Ретривер: dense-only

■ — Стало лучше
■ — Стало хуже
■ — Стат. незначимо

Изменения	C. Precision	C. Recall	Answer Rel.	Faithfulness
Судья 10B	0.76	0.92	0.74	0.90
Судья 235B	0.55	0.75	0.70	0.70
Генератор 3B (4-bit) + новый промпт	0.53 (-4%)	0.76 (+0.3%)	0.67 (-13.6%)	0.86 (+21.9%)
Предобработка данных	0.56 (+7.3%)	0.75 (-1.2%)	0.82 (+22.2%)	0.84 (-2.4%)

- Этап препроцессинга данных: заставляем парсеры лучше чистить мусор
- Чанкование: используем семантические сплиттеры
- Векторизация: попробовать эмбеддеры тяжелее
- Ретривер: делаем гибридный поиск (Косинус + BM25)
- Ретривер: добавляем реранкер
- Генератор: используем LLM тяжелее, чем 1.5B
- GraphRAG: переходим к графовым представлениям статей, т.н. «граф знаний»
- ВАЖНО: Каждое улучшение пайплайна требует замера метрик